



PONTIFÍCIA UNIVERSIDADE CATÓLICA DE MINAS GERAIS  
Instituto de Ciências Exatas e de Informática

## Segmentação e Classificação de Imagens Mamográficas\*

Daniel Vitor de Oliveira Santos<sup>1</sup>  
Guilherme Cosso Lima Pimenta<sup>2</sup>  
Larissa Kaweski Siqueira<sup>3</sup>

### Resumo

A segmentação e classificação de imagens mamográficas desempenham um papel fundamental no diagnóstico precoce e preciso do câncer de mama, uma das principais causas de morte entre mulheres em todo o mundo. Neste artigo, abordamos o desenvolvimento de técnicas de segmentação e classificação para auxiliar na análise de imagens mamográficas, com foco na identificação de regiões de interesse e na classificação com base na escala de densidade chamada BIRADS. Através da interface gráfica, os radiologistas e médicos podem interagir diretamente com as imagens mamográficas, realizando a classificação das mamografias de forma interativa e visualmente enriquecedora. A interface fornece uma variedade de ferramentas e recursos, como contraste por janelamento, zoom, drag e visualização em tempo real dos resultados de classificação.

**Palavras-chave:** Segmentação. Classificação. Interface. Mamografia.

---

\*Trabalho apresentado na disciplina de Processamento e Análise de Imagens da Pontifícia Universidade Católica de Minas Gerais no curso de Ciência da Computação.

<sup>1</sup> Aluno do Programa de Graduação em Ciência da Computação, Brasil – daniel.santos.1296076@sga.pucminas.br.

<sup>2</sup> Aluno do Programa de Graduação em Ciência da Computação, Brasil – gclpimenta@sga.pucminas.br.

<sup>3</sup> Aluno do Programa de Graduação em Ciência da Computação, Brasil – larissa.kaweski@sga.pucminas.br.

### **Abstract**

Segmentation and classification of mammographic images play a crucial role in the early and accurate diagnosis of breast cancer, one of the leading causes of death among women worldwide. In this article, we address the development of segmentation and classification techniques to assist in the analysis of mammographic images, focusing on the identification of regions of interest and classification based on the Breast Imaging Reporting and Data System (BIRADS) density scale. Through the graphical interface, radiologists and physicians can directly interact with mammographic images, performing interactive and visually enhanced classification of mammograms. The interface provides a variety of tools and features, such as window-level contrast, zoom, drag, and real-time visualization of classification results.

**Keywords:** Segmentation. Classification. Interface. Mammography.

## 1 INTRODUÇÃO


O câncer de mama é uma das principais causas de morte entre mulheres em todo o mundo, destacando a necessidade crítica de um diagnóstico precoce e preciso. A segmentação e classificação de imagens mamográficas desempenham um papel fundamental para alcançar esse objetivo. Neste artigo, o objetivo principal da nossa pesquisa é auxiliar na classificação com base na escala de densidade do Sistema de Relatórios e Dados de Imagens Mamográficas (BIRADS), logo, a abordagem visa melhorar a eficiência e a eficácia do diagnóstico do câncer de mama. Os tipos podem ser observados na Figura 1.

O sistema BIRADS foi desenvolvida pelo American College of Radiology e informa os radiologistas sobre a diminuição da sensibilidade do exame com o aumento da densidade da mama. O BI-RADS definem a densidade como sendo quase inteiramente composta por:

1. Gordura (densidade I).
2. Tecido fibroproliferativo difuso (densidade II).
3. Tecido denso heterogêneo (III).
4. tecido extremamente denso (IV).

Ao longo deste artigo, apresentaremos a metodologia empregada em nossa pesquisa, incluindo os algoritmos utilizados nas tarefas de segmentação e classificação. Também discutiremos os detalhes de implementação da interface gráfica e destacaremos seus recursos-chave que possibilitam uma análise de imagem eficiente e intuitiva.

Além disso, avaliaremos o desempenho de nossas técnicas propostas usando um conjunto abrangente de imagens mamográficas. Essa avaliação envolverá a comparação dos resultados obtidos com nossa abordagem com anotações de referência e métodos existentes na área. Esperamos que nosso método demonstre uma maior precisão, sensibilidade e especificidade, resultando em diagnósticos de câncer de mama mais confiáveis.



**Figura 1 – Tipos de densidade.**

## 2 DESENVOLVIMENTO

Nesta seção, apresentaremos em detalhes o desenvolvimento das técnicas de segmentação e classificação de imagens mamográficas, bem como a implementação da interface gráfica para análise interativa. Abordaremos os principais aspectos metodológicos, algoritmos utilizados e recursos implementados para alcançar os objetivos propostos.

### 2.1 Base de dados

Com relação aos dados utilizados para o desenvolvimento do trabalho, as imagens fornecidas continham uma numeração, sendo que as imagens com múltiplo de 4 foram separadas para teste e as demais para treino. As classes de BIRADS I, II, III e IV eram classificadas com a letra D, E, F e G respectivamente. No conjunto de dados, existem imagens para a mama direita (right) e esquerda (left), tomadas nas orientações crânio-caudal (CC) e médio-lateral (MLO). O conjunto está balanceado com 314 imagens em cada combinação de classe, mama e orientação, no total de 5024 imagens (1256 para teste e as demais para treino).

### 2.2 Segmentação das imagens

Para a segmentação das imagens mamográficas, utilizamos inicialmente uma redução no tamanho da imagem, removendo 15 pixels de todas as bordas. Posteriormente aplicamos uma transformação gamma para filtrar a imagem e facilitar na próxima etapa de segmentação. Logo após, baseado no valor do gamma encontrando em uma função de otimização, fazemos a escolha de qual método é mais adequado para a imagem. Se o valor do gamma for maior ou igual a 0.6, aplicamos a transformação gamma e o método de Otsu para segmentar a imagem. Caso contrário, aplicamos uma limialização com threshold 1 para segmentar a imagem. Por fim, fazemos a escolha do maior objeto da imagem para remoção das notações e ruídos que não fazem parte da mama. Ou seja, os métodos principais foram threshold binary e otsu, de acordo com o gamma.

A binarização com threshold 1 é um método simples em que todos os pixels com valor acima de um determinado limite são atribuídos a uma classe e os pixels com valor abaixo desse limite são atribuídos a outra classe. No caso específico do threshold 1, apenas dois valores são possíveis: 0 e 1, representando as classes de interesse.

A segmentação por Otsu, por outro lado, é um método de binarização adaptativo que busca determinar automaticamente o valor ótimo do limite de intensidade para separar os objetos da imagem. O algoritmo de Otsu calcula a variância intraclasse para diferentes valores de limiar e seleciona o limiar que minimiza a variância intraclasse.

## 2.3 Aumento dos dados

O aumento dos dados consiste em aplicar transformações específicas às imagens existentes, gerando novas instâncias de treinamento com variações, mas que ainda são semanticamente equivalentes às originais. Essa técnica foi utilizada com o objetivo de melhorar a capacidade de generalização do modelo. Ao introduzir variações nas imagens de treinamento, o modelo se torna mais robusto a diferentes condições e variações encontradas nos dados de teste. Esse aumento de dados foi aplicado apenas as imagens de treinamento, gerando 4 variações da mesma imagem:

1. Imagem original.
2. Imagem equalizada.
3. Imagem espelhada.
4. Imagem equalizada e espelhada.

## 2.4 Balanceamento dos dados

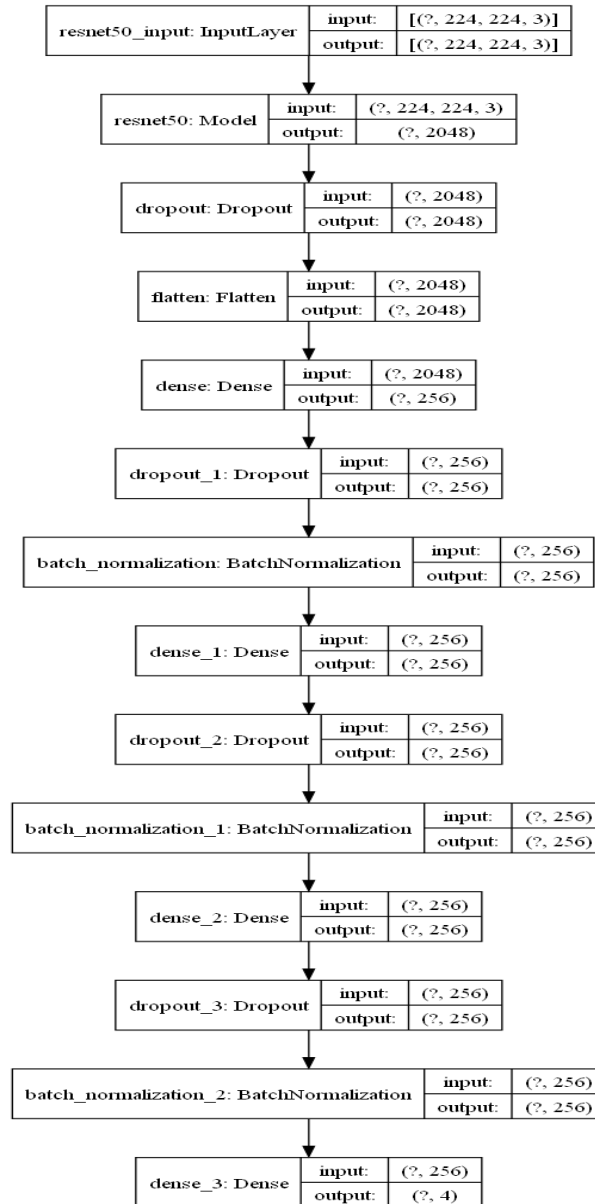
Dentro do contexto das imagens já segmentadas e com a aplicação do aumento de dados, a base de dados de treino, validação e teste foram balanceadas, a fim de prevenir viés do modelo, melhorar a generalização e aumentar a precisão. No conjunto de treino, ocorreu um split de 80/20 para treino e validação, respectivamente, sendo que a base de dados de treino contava com 3020 imagens de cada classe, enquanto a base de validação contava com 756 imagens de cada classe. No conjunto de teste, existem 312 imagens para cada classe.

## 2.5 Arquitetura do modelo

Nesse trabalho, utilizados a ResNet50 como rede base para o treinamento das imagens. A arquitetura da ResNet50 é composta por 50 camadas, incluindo camadas convolucionais, camadas de agrupamento e camadas totalmente conectadas. As conexões residuais são introduzidas por meio de blocos residuais, que são unidades básicas compostas por múltiplas camadas convolucionais empilhadas. Essa abordagem permite que a rede aprenda atalhos e informações residuais, facilitando o fluxo das informações ao longo das camadas e permitindo o treinamento eficiente de redes profundas com excelente desempenho em várias tarefas de visão computacional.

Além disso, foram adicionadas camadas a mais para ajudar no processo de treinamento da rede, como camadas densas, camadas de flatten, dropout e batch normalization. Ou seja, o modelo criado é uma arquitetura de rede neural sequencial que utiliza a ResNet50 como

uma camada de base pré-treinada, com os pesos da imageNet e `pooling=average`. Logo após temos uma camada de dropout com uma taxa de 0.2, a fim de regularizar e evitar overfitting. Posteriormente temos uma camada de flatten, transformando os tensores de entrada em um vetor unidimensional. Ademais, são adicionadas 3 camadas densas de 256 unidades com função de ativação ReLU, com dropout de 0.2 e batch normalization para acelerar no treinamento. Por fim, existe uma camada densa de 4 neurônios com softmax para produzir a saída final do modelo. Na figura 2 podemos ver a arquitetura completa.



**Figura 2 – Arquitetura do modelo**

## 2.6 Hiperparâmetros


Os hiperparâmetros são escolhas configuráveis do modelo e geralmente são definidos com base na experiência, conhecimento do domínio ou por meio de técnicas de otimização. Eles

determinam as características fundamentais do modelo, como sua complexidade, capacidade de generalização, velocidade de treinamento e sensibilidade aos dados de entrada. Os hiperparâmetros definidos no nosso modelo foram: image size=224, batch size=32, optimizer=SGD(lr=0.01, decay=1e-6, momentum=0.9, nesterov=True), loss='categorical\_crossentropy'. metric=['accuracy'] e 30 epochs.

Também foi utilizado um ModelCheckpoint para salvar a época que teve o melhor desempenho com relação a acurácia do conjunto de validação.

## 2.7 Interface gráfica

A interface desenvolvida foi projetada para ser altamente intuitiva e de fácil utilização, com uma interface de usuário limpa e amigável. Os elementos de navegação e interação são claros e bem organizados, tornando a análise das imagens uma tarefa fluida e eficiente. A tela inicial possui alguns ícones para carregamento de imagem, abrir e fechar a sidebar, além de contem opções de zoom, drag, contraste por janelamento, segmentação e classificação do tipo binária e multiclasse. Após fazer a classificação, o resultado do modelo, assim como a sua precisão e seu tempo para classificação são exibidos.



**Figura 3 – Imagem classificada sem segmentação.**

## 3 RESULTADOS

Essa sessão busca discutir os resultados obtidos no modelo para os dados segmentados e não segmentados, cada um deles será analisado e feita uma breve descrição do processo

utilizado para chegar aos resultados e as métricas obtidas.

### 3.1 Imagens não segmentadas (4 classes)

Nas imagens não segmentadas e com 4 classes, utilizando a arquitetura apresentada acima. Ao analisar os resultados, é essencial considerar métricas como acurácia geral, precisão, recall, F1-score e matriz de confusão. Essas métricas fornecem uma visão mais abrangente do desempenho do modelo em relação a cada classe individualmente e ao conjunto de dados como um todo.





Figura 4 – Resultados do treinamento.



	precision	recall	f1-score	support
I	0.6111	0.0353	0.0667	312
II	0.0000	0.0000	0.0000	312
III	0.2537	1.0000	0.4047	312
IV	0.0000	0.0000	0.0000	312
accuracy			0.2588	1248
macro avg	0.2162	0.2588	0.1178	1248
weighted avg	0.2162	0.2588	0.1178	1248

(b) Classification report

```
Accuracy: 25.88%
Precision: 21.62%
Recall (Sensibility): 25.88%
Mean Specificity: 75.29%
F1-Score: 11.78%
```


(c) Métricas

Figura 5 – Métricas para avaliação.

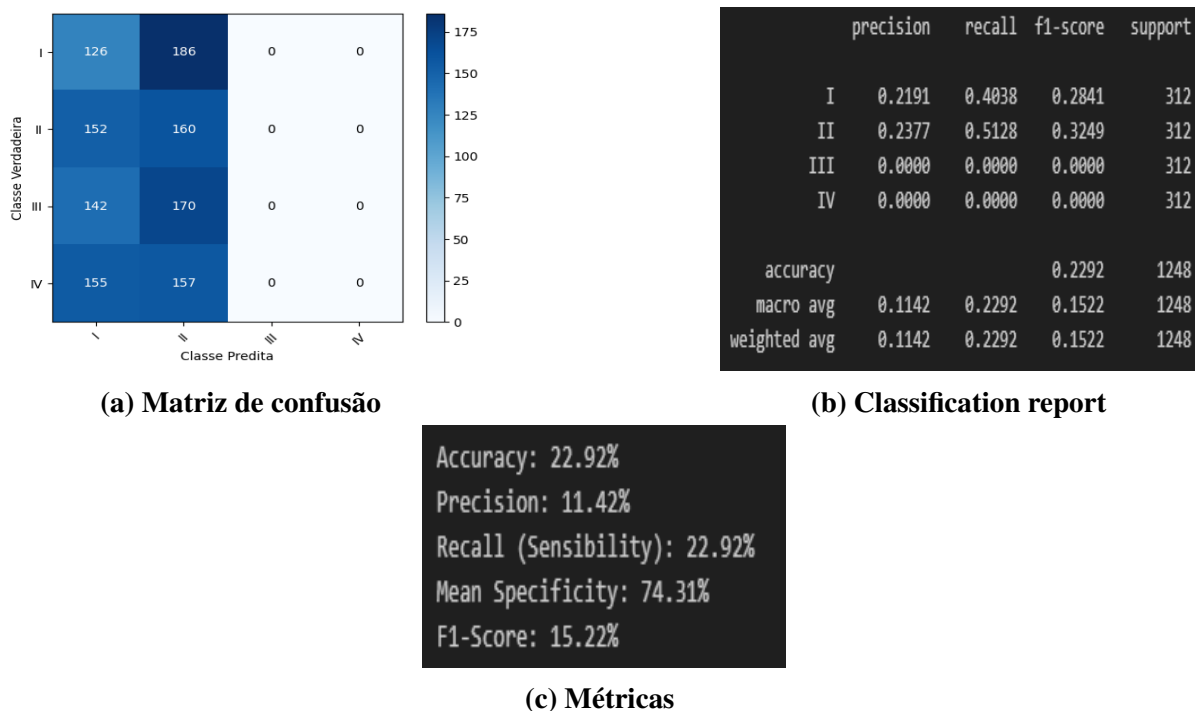


### 3.2 Imagens segmentadas (4 classes)

Nas imagens segmentadas e com 4 classes, o desempenho do modelo foi superior as imagens não segmentadas, com os seguintes resultados:



**Figura 6 – Resultados do treinamento.**



**Figura 7 – Métricas para avaliação.**

### 3.3 Imagens não segmentadas (2 classes)

Nas imagens não segmentadas e com 2 classes, utilizando a arquitetura apresentada acima, o modelo obteve os seguintes resultados. Sua acurácia geral foi de 62.5%.

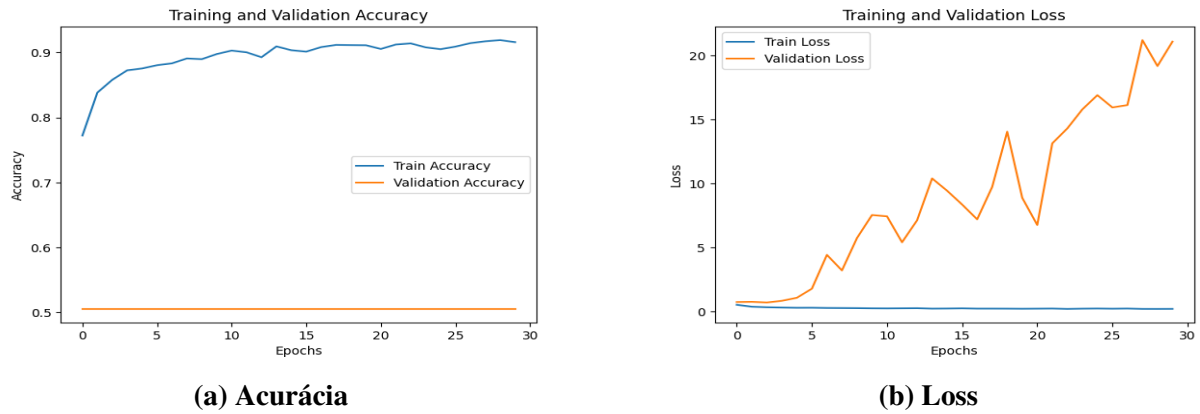


Figura 8 – Resultados do treinamento.

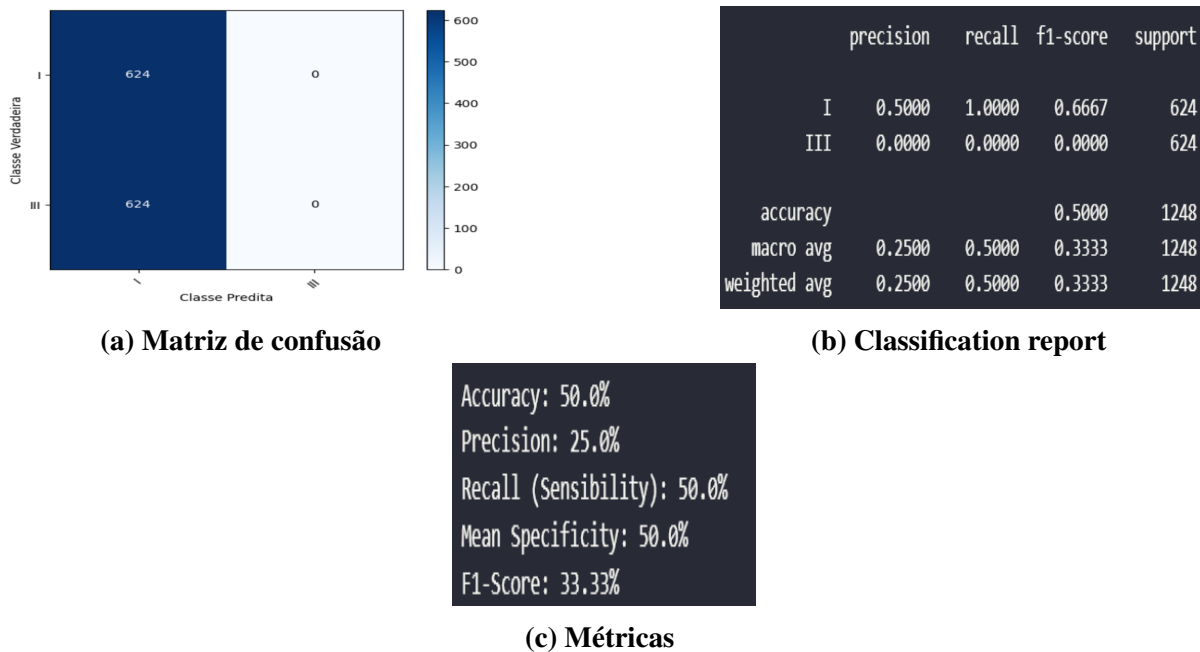




Figura 9 – Métricas para avaliação.

### 3.4 Imagens segmentadas (2 classes)

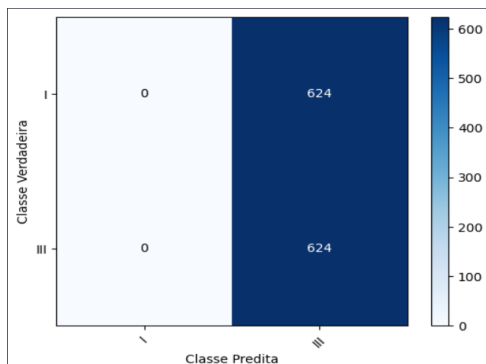
Nas imagens segmentadas e com 2 classes, o desempenho do modelo foi pior que as imagens não segmentadas, com os seguintes resultados. Sua acurácia geral foi de 51%. É importante ressaltar que a acurácia geral por si só pode não ser uma métrica completa para avaliar o desempenho de um modelo de segmentação. Em problemas de segmentação, outras métricas, como a precisão, recall e F1-score, podem fornecer uma visão mais abrangente do desempenho em cada classe individualmente, permitindo uma análise mais detalhada. Para melhorar o desempenho do modelo em imagens segmentadas com duas classes, algumas abordagens podem ser consideradas, como o aumento do tamanho e qualidade do conjunto de dados de treinamento, a exploração de arquiteturas de rede mais avançadas, a otimização dos hiperparâmetros do modelo e a aplicação de técnicas de pré-processamento adequadas.



(a) Acurácia



(b) Loss

**Figura 10 – Resultados do treinamento.**

(a) Matriz de confusão

	precision	recall	f1-score	support
I	0.0000	0.0000	0.0000	624
III	0.5000	1.0000	0.6667	624
accuracy			0.5000	1248
macro avg	0.2500	0.5000	0.3333	1248
weighted avg	0.2500	0.5000	0.3333	1248

(b) Classification report

```

Accuracy: 50.0%
Precision: 25.0%
Recall (Sensibility): 50.0%
Mean Specificity: 50.0%
F1-Score: 33.33%

```

(c) Métricas

**Figura 11 – Métricas para avaliação.**

## 4 CONCLUSÕES

Em conclusão, as técnicas desenvolvidas para segmentação de imagem e classificação de imagens mamográficas, juntamente com a interface gráfica implementada, visam obter uma análise precisa e eficiente das imagens mamárias. O estudo utilizou um conjunto de dados composto por imagens segmentadas e não segmentadas, com duas classes e quatro classes.

Os resultados mostraram que o desempenho do modelo em imagens segmentadas foi inferior ao de imagens não segmentadas. Isso indica que o processo de segmentação pode ter introduzido ruídos ou artefatos que afetaram a capacidade do modelo de classificar corretamente as imagens.

No entanto, é importante observar que o processo de segmentação e classificação envolveu várias etapas e escolhas, incluindo aumento de dados, arquitetura de modelo, seleção de

hiperparâmetros e o uso de pesos pré-treinados. Esses fatores podem afetar significativamente o desempenho do modelo.

Vale ressaltar também que a interface gráfica permitiram que os usuários examinassem detalhadamente as imagens, identificassem possíveis anormalidades e avaliassem a qualidade da segmentação realizada pelo modelo. A interface também facilitou a comparação entre as imagens originais e as segmentadas, auxiliando na validação dos resultados. Além disso, o contraste por janelamento ajudou a validar se existia uma melhora ou piora nos resultados de acordo com os valores de Max e Min utilizados.

Além disso, a interface proporcionou uma experiência visual agradável e organizada, com elementos de navegação bem definidos e disposição clara dos controles. Isso contribuiu para uma análise mais eficiente e uma compreensão mais rápida das características das imagens.

## **5 TRABALHOS FUTUROS**

Mais análises e investigações são necessárias para identificar os desafios e limitações específicos no processo de segmentação e explorar possíveis melhorias. Pode ser benéfico considerar técnicas de segmentação alternativas, refinar as estratégias de aumento de dados e explorar diferentes arquiteturas de modelo para aumentar a precisão e a confiabilidade dos resultados da classificação.

No geral, este trabalho fornece informações valiosas sobre o desenvolvimento de métodos de segmentação e classificação de imagens para imagens mamográficas, destacando a importância da preparação do conjunto de dados, escolha de técnicas e avaliação cuidadosa do desempenho do modelo. As descobertas podem servir como base para futuras pesquisas e avanços no campo da análise de imagens médicas para diagnóstico e tratamento do câncer de mama.

## **6 REFERÊNCIAS**

Arevalo, J., Gonzalez, F., Ramos-Pollán, R. (2015). Representation Learning for Mammography Mass Lesion Classification with Convolutional Neural Networks. *Computer Methods and Programs in Biomedicine*, 122(3), 474-482.

Dhungel, N., Carneiro, G., Bradley, A. P., Guyader, J. M. (2015). Deep Learning and Structured Prediction for the Segmentation of Mass in Mammograms. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 37(9), 1842-1855.

Ganesan, A., Acharya, U. R. (2019). Deep Learning-based Breast Cancer Classification using Histopathological Images. *Journal of Imaging*, 5(1), 6.

Ronneberger, O., Fischer, P., Brox, T. (2015). U-Net: Convolutional Networks for Biomedical Image Segmentation. In *International Conference on Medical Image Computing*

and Computer-Assisted Intervention (pp. 234-241). Springer.

Tajbakhsh, N., Shin, J. Y., Gurudu, S. R., Hurst, R. T., Kendall, C. B., Gotway, M. B., Liang, J. (2016). Convolutional Neural Networks for Medical Image Analysis: Full Training or Fine Tuning?. *IEEE Transactions on Medical Imaging*, 35(5), 1299-1312.

Gandomkar, Z., Brennan, P. C., Mello-Thoms, C., Ryan, J. (2017). Computer-Aided Detection and Diagnosis of Breast Cancer With Mammography: Recent Advances. *IEEE Transactions on Medical Imaging*, 36(11), 2366-2377.